



第1章 引言




李政伟

-----● 中国矿业大学 计算机科学与技术学院 ●-----



参考书目

■陈宝林，最优化理论与算法（第2版），清华大学出版社





目 录

第1章 引言

第2章 线性规划的基本性质

第3章 单纯性方法

第4章 对偶原理

第7章 最优性条件



1.1 学科概述

- **最优化理论与算法**：是一个重要的数学分支。
- **最优化**：从所有可能的方案中选择最合理的一种方案，构造寻求最优解的计算方法。
- **最优方案**：达到最佳目标的方案。
- **最优化方法(算法)**：寻找最优方案的方法。
- **最优化理论**：最优化方法的数学理论。

|| 最优化理论与算法简介

- 17世纪，在微积分时代已经出现了极值问题，后来又出现了Lagrange乘法；
- 1847年，法国数学家Cauchy提出了最速下降法；
- 19世纪40年代，第二次世界大战期间，优化问题在战争中得到了充分的运用和发展；
- 20世纪40年代以来，优化问题成为一门独立的学科，出现了线性规划、整数规划、非线性规划、几何规划等许多分支。

1.2 线性规划与非线性规划问题

例1 生产计划问题

设某工厂用4种资源生产3种产品，每单位第 j 种产品需要第 i 种资源的数量为 a_{ij} ，可获利润为 c_j ，第 i 种资源总消耗量不能超过 b_i ，由于市场限制，第 j 种产品的产量不超过 d_j ，试问如何安排生产才能使总利润最大？

解析： (1) 决策变量 $x_j (j = 1, 2, 3)$ 为第 j 种产品的产量

(2) 目标函数：总利润
$$f = c_1x_1 + c_2x_2 + c_3x_3 = (c_1, c_2, c_3) \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \mathbf{c}^T \mathbf{x}$$

(3) 约束条件

资源限制

$$\left. \begin{aligned} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 &\leq b_1 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 &\leq b_2 \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 &\leq b_3 \\ a_{41}x_1 + a_{42}x_2 + a_{43}x_3 &\leq b_4 \end{aligned} \right\} \sum_{j=1}^3 a_{ij}x_j \leq b_i \quad i=1, 2, 3, 4$$

例1 生产计划问题 (续)

资源限制

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \\ a_{41} & a_{42} & a_{43} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = Ax \leq b = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

市场销量限制

$$x_j < d_j \quad j = 1, 2, 3$$

产量非负限制

$$x_j \geq 0 \quad j = 1, 2, 3$$

例1 生产计划问题 (续)

在一组约束条件下，确定一个最优生产方案 $x^* = (x_1^*, x_2^*, x_3^*)$ ，使目标函数值最大。数学模型如下：

$$\max \sum_{j=1}^3 c_j x_j$$

$$\text{s. t. } \sum_{j=1}^3 a_{ij} x_j \leq b_i, \quad i = 1, 2, 3, 4,$$

$$x_j < d_j \quad j = 1, 2, 3,$$

$$x_j \geq 0 \quad j = 1, 2, 3.$$

例2 食谱问题

设市场上可买到 n 种不同的食品，第 j 种食品单位售价为 c_j ，每种食品含有 m 种基本营养成分，第 j 种食品每个单位含第 i 种营养成分为 a_{ij} ，又设每人每天对第 i 种营养成分的需要量不少于 b_i ，试确定在保证营养要求条件下的最经济食谱。

解析：（1）决策变量： $x_j (j = 1, \dots, n)$ 为第 j 种产品的产量

（2）目标函数：

$$\min \sum_{j=1}^n c_j x_j$$

（3）约束条件：

$$\text{s. t. } \sum_{j=1}^n a_{ij} x_j \geq b_i, \quad i = 1, \dots, m$$

$$x_j \geq 0 \quad j = 1, \dots, n$$

例3 结构设计问题

以两个构件组成的对称桁架为例。已知桁架的跨度 $2L$ ，高度 x_2 的上限 H ，承受负荷 $2P$ ，钢管的厚度 T ，材料比重 ρ ，纵向弹性模量 E 及容许应力 σ_y 。试确定钢管的平均直径 x_1 及桁架的高度 x_2 ，使桁架的重量最小。

解析 对应的数学模型为：


$$\min 2\pi\rho T x_1 \sqrt{L^2 + x_2^2}$$

$$\text{s. t. } x_2 \leq H,$$

$$\frac{P\sqrt{L^2 + x_2^2}}{\pi T x_1 x_2} \leq \sigma_y,$$

$$\frac{P\sqrt{L^2 + x_2^2}}{\pi T x_1 x_2} \leq \frac{\pi^2 E (T^2 + x_1^2)}{8(L^2 + x_2^2)},$$

$$x_1, x_2 \geq 0.$$



最优化问题的模型及分类

一、最优化问题的模型

决策变量

$$\begin{cases} \min f(\mathbf{x}) \\ \text{s.t. } g_i(\mathbf{x}) \leq 0 \quad i = 1, 2, \dots, m_i \\ \quad \quad h_j(\mathbf{x}) = 0 \quad j = 1, 2, \dots, m_j \\ \quad \quad x \in X \quad X \subset R^n \end{cases}$$

目标函数

不等式约束

等式约束

箱子约束

最优化问题分类

- **线性规划问题**：模型中的目标函数和约束函数都是**线性**的；
- **非线性规划问题**：模型中含有**非线性**函数。

基本概念

可行点：满足约束条件的点。


可行集（可行域）：全体可行点组成的集合。

$$F = \{x | g_i(x) \leq 0 \quad i = 1, 2, \dots, m_i, h_j(x) = 0 \quad j = 1, 2, \dots, m_j, x \in X\}$$

无约束问题：如果一个问题的可行集是整个空间。

定义1.2.1 设 $f(x)$ 为目标函数， S 为可行域， $\bar{x} \in S$ ，若对每个 $x \in S$ ，成立 $f(x) \geq f(\bar{x})$ ，则称 \bar{x} 为 $f(x)$ 在 S 上的**全局极小点**。

定义1.2.2 设 $f(x)$ 为目标函数， S 为可行域，若存在 $\bar{x} \in S$ 的 $\varepsilon > 0$ 邻域 $N(\bar{x}, \varepsilon) = \{x | |x - \bar{x}| < \varepsilon\}$ ，使得对每个 $x \in S \cap N(\bar{x}, \varepsilon)$ 成立 $f(x) \geq f(\bar{x})$ ，则称 \bar{x} 为 $f(x)$ 在 S 上的一个**局部极小点**。



注：全局极小点也是局部极小点，而局部极小点不一定是全局极小点。

机器学习中的优化问题

(1) L_2 范数正则

$$\min L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (f(x_i; \mathbf{w}) - y_i)^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2$$

(2) L_1 范数正则

$$\min L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (f(x_i; \mathbf{w}) - y_i)^2 + \frac{\lambda}{2} \|\mathbf{w}\|$$

(3) 感知机模型

$$\min L(\mathbf{w}, \mathbf{b}) = - \sum_{i=1}^N y_i (\mathbf{w}x_i + \mathbf{b})$$



1.3 几个数学概念

定义1.3.1 若实值函数 $\|\cdot\|: \mathbb{R}^n \rightarrow \mathbb{R}$ 满足下面条件:

- (1) 正定型: $\|x\| \geq 0, \forall x \in \mathbb{R}^n; \|x\| = 0$ 当且仅当 $x = 0$;
 - (2) 齐次性: $\|\alpha x\| = |\alpha| \|x\|, \forall \alpha \in \mathbb{R}, x \in \mathbb{R}^n$
 - (2) 三角不等式: $\|x + y\| \leq \|x\| + \|y\|, \forall x, y \in \mathbb{R}^n$
- 则称 $\|\cdot\|$ 为 \mathbb{R}^n 上的**向量范数**。

常见范数: 设 $x = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$


L_1 范数 $\|x\|_1 = \sum_{j=1}^n |x_j|$

L_2 范数 $\|x\|_2 = \left(\sum_{j=1}^n x_j^2 \right)^{\frac{1}{2}}$

L_∞ 范数 $\|x\|_\infty = \max_j |x_j|$

L_p 范数

$$\|x\|_p = \left(\sum_{j=1}^n |x_j|^p \right)^{\frac{1}{p}}$$



https://blog.csdn.net/weixin_4971

1.3.1 向量范数和矩阵范数

定义1.3.2 设 $\|\cdot\|_\alpha$ 和 $\|\cdot\|_\beta$ 是 \mathbb{R}^n 上任意两个范数, 如果存在正数 c_1 和 c_2 , 使得对每个 $\mathbf{x} \in \mathbb{R}^n$ 成立 $c_1\|\mathbf{x}\|_\alpha \leq \|\mathbf{x}\|_\beta \leq c_2\|\mathbf{x}\|_\alpha$, 则称范数 $\|\mathbf{x}\|_\alpha$ 和范数 $\|\mathbf{x}\|_\beta$ 等价。在 \mathbb{R}^n 中任何两种向量范数都是等价的。

定义1.3.3 设 \mathbf{A} 是 $m \times n$ 矩阵, $\|\cdot\|_\alpha$ 是 \mathbb{R}^m 上的范数, $\|\cdot\|_\beta$ 是 \mathbb{R}^n 上的范数, 则定义矩阵范数 $\|\mathbf{A}\| = \max_{\|\cdot\|_\beta=1} \|\mathbf{A}\mathbf{x}\|_\alpha$ 。

若对于任意 $\mathbf{A} \in \mathbb{R}^{n \times n}$, 都有一个矩阵范数 $\|\mathbf{A}\|$ 与之对应, 且满足:

- (1) 非负性: $\|\mathbf{A}\| \geq 0$, 当且仅当 $\mathbf{A} = \mathbf{0}$ 时, $\|\mathbf{A}\| = 0$
- (2) 齐次性: $\|\lambda\mathbf{A}\| = |\lambda|\|\mathbf{A}\|, \forall \lambda \in \mathbb{R}$
- (3) 三角不等式: $\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|$
- (4) 相容性: $\|\mathbf{AD}\| \leq \|\mathbf{A}\|\|\mathbf{D}\|, \mathbf{A}, \mathbf{D} \in \mathbb{R}^{n \times n}$

1.3.1 向量范数和矩阵范数

常用矩阵范数:

$$\|A\|_1 = \max_j \sum_{i=1}^m |a_{ij}|$$

$$\|A\|_2 = \sqrt{\lambda_{A^T A}}$$

$\lambda_{A^T A}$ 是 $A^T A$ 的最大特征值。 $\|A\|_2$ 又称为谱范数。

$$\|A\|_\infty = \max_i \sum_{j=1}^n |a_{ij}|$$



1.3.2 序列的极限

定义1.3.4 设 $\{x^{(k)}\}$ 是 \mathbb{R}^n 中一个向量序列, $\bar{x} \in \mathbb{R}^n$, 如果对每个任给的 $\varepsilon > 0$ 存在正整数 K_ε , 使得当 $k > K_\varepsilon$ 时就有 $\|x^{(k)} - \bar{x}\| < \varepsilon$, 则称序列收敛到 \bar{x} , 或称序列以 \bar{x} 为极限, 记作 $\lim_{k \rightarrow \infty} x^{(k)} = \bar{x}$ 。

注意: 序列极限若存在, 则必定唯一。

定义1.3.4 设 $\{x^{(k)}\}$ 是 \mathbb{R}^n 中一个向量序列, 若存在一个子序列 $\{x^{(k_j)}\}$, 使 $\lim_{k \rightarrow \infty} x^{(k_j)} = \hat{x}$, 则称 \hat{x} 是序列 $\{x^{(k)}\}$ 的一个聚点。

$\{1, -1, 1, -1, 1, -1, 1, -1, \dots\}$ 振荡, 没有极限, 但是有聚点。

定义1.3.6 设 $\{x^{(k)}\}$ 是 \mathbb{R}^n 中一个向量序列, 如果对任意给定的 $\varepsilon > 0$, 总存在正整数 K_ε , 使得当 $m, l > K_\varepsilon$ 时, 就有 $\|x^{(m)} - x^{(l)}\| < \varepsilon$, 则 $\{x^{(k)}\}$ 称为Cauchy序列。

设集合 S 是 \mathbb{R}^n 中的一个集合, 如果 S 中的每个收敛序列的极限均属于 S , 则 S 为闭集。如果对每个点 $\hat{x} \in S$, 存在正数 ε , 使得 \hat{x} 的 ε 邻域 $N(\hat{x}, \varepsilon) = \{x | \|x - \hat{x}\| < \varepsilon\} \subset S$, 则称 S 为开集。

如果 S 是有界闭集, 则称 S 为紧集。

1.3.3 梯度、Hesse矩阵、Taylor展开式

设集合 $S \subset \mathbb{R}^n$ 非空, $f(x)$ 为定义在 S 上的实函数。如果 f 在每一点 $x \in S$ 连续, 则称 f 在 S 上连续, 记作 $f \in C(S)$ 。再设 S 为开集, 如果在每一点 $x \in S$, 对所有 $j = 1, \dots, n$, 偏导数 $\frac{\partial f(x)}{\partial x_j}$ 存在且连续, 则称 f 在开集 S 上连续可微, 记作 $f \in C^1(S)$ 。

如果在每一点 $x \in S$, 对所有 $i = 1, \dots, n$ 和 $j = 1, \dots, n$, 二阶偏导数 $\frac{\partial^2 f(x)}{\partial x_i \partial x_j}$ 存在且连续, 则称 f 在开集 S 上二次连续可微, 记作 $f \in C^2(S)$ 。

函数 f 在 x 处的梯度为 n 维列向量:

$$\nabla f(x) = \left[\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right]^T,$$

f 在 x 处的 Hesse 矩阵为 $n \times n$ 矩阵 $\nabla^2 f(x)$, 第 i 行第 j 列元素为

$$[\nabla^2 f(x)]_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}, \quad 1 \leq i, j \leq n$$

1.3.3 梯度、Hesse矩阵、Taylor展开式

例4, $f(\mathbf{x}) = \mathbf{c}^T \mathbf{x}, \mathbf{c} \in \mathbb{R}^n, \mathbf{x} \in \mathbb{R}^n$, 计算 $\nabla f(\mathbf{x})$ 。

解: $f(\mathbf{x}) = c_1 x_1 + c_2 x_2 + \cdots + c_n x_n$

$$\nabla f(\mathbf{x}) = \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{pmatrix} = \mathbf{c}$$

例5, $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x} + c, \mathbf{A}^T = \mathbf{A}, \mathbf{b} \in \mathbb{R}^n, c \in \mathbb{R}$, 计算 $\nabla f(\mathbf{x})$ 、 $\nabla^2 f(\mathbf{x})$ 。

解: $\nabla f(\mathbf{x}) = \mathbf{A} \mathbf{x} + \mathbf{b}$

$$\nabla^2 f(\mathbf{x}) = \mathbf{A}$$



1.3.3 梯度、Hesse矩阵、Taylor展开式

$f(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x}$, 其中 $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{A} \in \mathbb{R}^{n \times n}$, 则 $\nabla f(\mathbf{x}) = (\mathbf{A}^T + \mathbf{A})\mathbf{x}$

推导1:

$$f(\mathbf{x}) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j$$

$$\frac{\partial f(\mathbf{x})}{\partial x_k} = \sum_{j=1}^n a_{kj} x_j + \sum_{i=1}^n a_{ik} x_i$$

$$\begin{aligned}\nabla f(\mathbf{x}) &= \mathbf{x}^T \mathbf{A}^T + \mathbf{x}^T \mathbf{A} \\ &= (\mathbf{A}^T + \mathbf{A})\mathbf{x}\end{aligned}$$

推导2:

$$\begin{aligned}d(f(\mathbf{x})) &= (\mathbf{x}^T \mathbf{A})d\mathbf{x} + d(\mathbf{x}^T \mathbf{A})\mathbf{x} \\ &= \mathbf{x}^T \mathbf{A}d\mathbf{x} + \mathbf{x}^T d(\mathbf{A}^T \mathbf{x}) \\ &= \mathbf{x}^T \mathbf{A}d\mathbf{x} + \mathbf{x}^T \mathbf{A}^T d\mathbf{x} \\ &= \mathbf{x}^T (\mathbf{A}^T + \mathbf{A})d\mathbf{x} \\ &= (\mathbf{A}^T + \mathbf{A})\mathbf{x}d\mathbf{x}\end{aligned}$$

$$\nabla f(\mathbf{x}) = (\mathbf{A}^T + \mathbf{A})\mathbf{x}$$



1.3.3 梯度、Hesse矩阵、Taylor展开式

$$f: \mathbb{R} \rightarrow \mathbb{R}$$

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + o(x - x_0)$$

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{1}{2}f''(x_0)(x - x_0)^2 + o((x - x_0)^2)$$

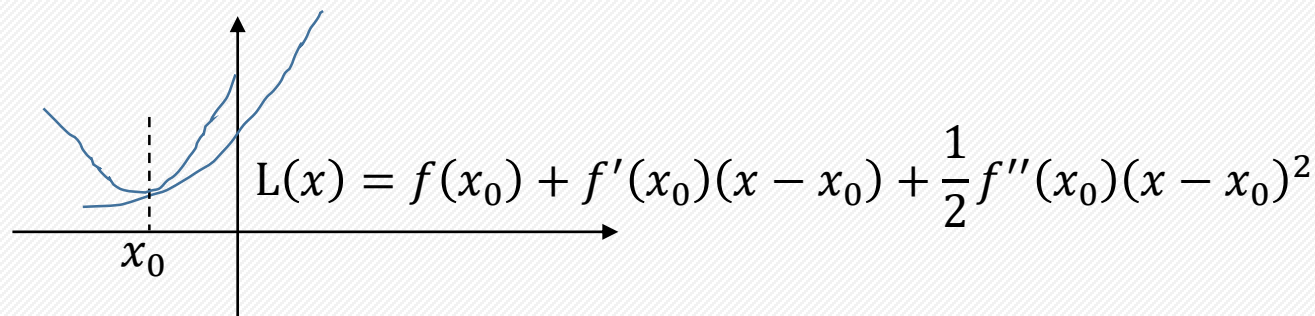

假设在开集 $S \subset \mathbb{R}^n$ 上 $f \in C^1(S)$, 给定点 $\mathbf{x} \in S$, 则 f 在点 $\bar{\mathbf{x}}$ 的一阶Taylor展开式为

$$f(\mathbf{x}) = f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})^T (\mathbf{x} - \bar{\mathbf{x}}) + o(\|\mathbf{x} - \bar{\mathbf{x}}\|),$$

其中 $o(\|\mathbf{x} - \bar{\mathbf{x}}\|)$ 当 $\|\mathbf{x} - \bar{\mathbf{x}}\| \rightarrow 0$ 时, 关于 $\|\mathbf{x} - \bar{\mathbf{x}}\|$ 是高阶无穷小。

假设在开集 $S \subset \mathbb{R}^n$ 上 $f \in C^2(S)$, 则 f 在 $\mathbf{x} \in S$ 的二阶Taylor展开式为

$$f(\mathbf{x}) = f(\bar{\mathbf{x}}) + \nabla f(\bar{\mathbf{x}})^T (\mathbf{x} - \bar{\mathbf{x}}) + \frac{1}{2}(\mathbf{x} - \bar{\mathbf{x}})^T \nabla^2 f(\bar{\mathbf{x}})(\mathbf{x} - \bar{\mathbf{x}}) + o(\|\mathbf{x} - \bar{\mathbf{x}}\|^2),$$





1.3.4 Jacobi矩阵、链式法则和隐函数存在定理

1. Jacobi 矩阵

考虑向量值函数 $\mathbf{h}(\mathbf{x}) = (h_1(\mathbf{x}), h_2(\mathbf{x}), \dots, h_m(\mathbf{x}))^T$,

其中每个分量 $h_i(\mathbf{x})$ 为 n 元实值函数, 假设对所有 i, j 偏导数 $\frac{\partial h_i(\mathbf{x})}{\partial x_j}$ 存在。 \mathbf{h} 在点 \mathbf{x} 的

Jacobi 矩阵为

$$\begin{bmatrix} \frac{\partial h_1(\mathbf{x})}{\partial x_1} & \frac{\partial h_1(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial h_1(\mathbf{x})}{\partial x_n} \\ \frac{\partial h_2(\mathbf{x})}{\partial x_1} & \frac{\partial h_2(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial h_2(\mathbf{x})}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial h_m(\mathbf{x})}{\partial x_1} & \frac{\partial h_m(\mathbf{x})}{\partial x_2} & \cdots & \frac{\partial h_m(\mathbf{x})}{\partial x_n} \end{bmatrix}$$

这个矩阵称为向量值函数 \mathbf{h} 在 \mathbf{x} 的导数, 记作 $\mathbf{h}'(\mathbf{x})$ 或 $\nabla \mathbf{h}(\mathbf{x})^T$, 其中 $\nabla \mathbf{h}(\mathbf{x}) = (\nabla h_1(\mathbf{x}), \nabla h_2(\mathbf{x}), \dots, \nabla h_m(\mathbf{x}))$

1. Jacobi 矩阵

例6 设有向量值函数

$$f(\boldsymbol{x}) = f(x_1, x_2) = \begin{bmatrix} \sin x_1 + \cos x_2 \\ e^{2x_1+x_2} \\ 2x_1^2 + x_1x_2 \end{bmatrix}$$

则 $f(\boldsymbol{x})$ 在任一点 (x_1, x_2) 的Jacobi矩阵, 即导数为

$$f'(\boldsymbol{x}) = \begin{bmatrix} \cos x_1 & -\sin x_2 \\ 2e^{2x_1+x_2} & e^{2x_1+x_2} \\ 4x_1 + x_2 & x_1 \end{bmatrix}$$

2.链式法则

设有复合函数 $h(x) = f(g(x))$, 其中向量值函数 $f(g)$ 和 $g(x)$ 均可微, $x \in D^n \subset \mathbb{R}^n$, $g: D^n \rightarrow D_1^m, f: D_2^m \rightarrow \mathbb{R}^k$, 其中 $D_1^m \subset D_2^m$, $h: D^n \rightarrow \mathbb{R}^k$ 。

根据复合函数求导数的链式法则, 必有

$$h'(x) = f'(g(x))g'(x), x \in D^n \quad (1.3.4)$$

其中 f' 和 g' 分别为 $k \times m$ 和 $m \times n$ 矩阵, h' 为 $k \times n$ 矩阵。

若记 $\nabla f = (\nabla f_1, \nabla f_2, \dots, \nabla f_k)$, $\nabla g = (\nabla g_1, \nabla g_2, \dots, \nabla g_m)$,

由于 $h' = \nabla h^T$, $f' = \nabla f^T$ 和 $g' = \nabla g^T$, 可将(1.3.4)式改写为

$$\nabla h(x) = \nabla g(x) \nabla f(g(x)) \quad (1.3.5)$$

其中, ∇h 为 $n \times k$ 矩阵, 第 j 列为 ∇f_j 的 $h_j(x)$ 梯度。



2.链式法则

例7 设有复合函数 $h(x) = f(u(x))$, 其中

$$f(u) = \begin{bmatrix} f_1(u) \\ f_2(u) \end{bmatrix} = \begin{bmatrix} u_1^2 - u_2 \\ u_1 + u_2^2 \end{bmatrix} \quad u(x) = \begin{bmatrix} u_1(x) \\ u_2(x) \end{bmatrix} = \begin{bmatrix} x_1 + x_2 \\ x_2^2 - x_3 \end{bmatrix}$$

试求复合函数 $h(x) = f(u(x))$ 的导数.

解: $h'(x) = f'(u(x)) u'(x)$

$$= \begin{bmatrix} 2u_1 & -1 \\ 1 & 2u_2 \end{bmatrix} \begin{bmatrix} 1 & 0 & 1 \\ 0 & 2x_2 & -1 \end{bmatrix} = \begin{bmatrix} 2u_1 & -2x_2 & 2u_1 + 1 \\ 1 & 4u_2x_2 & 1 - 2u_2 \end{bmatrix}$$

将 u 代替 x , 得到

$$\begin{bmatrix} \frac{\partial h_1(x)}{\partial x_1} & \frac{\partial h_1(x)}{\partial x_2} & \frac{\partial h_1(x)}{\partial x_3} \\ \frac{\partial h_2(x)}{\partial x_1} & \frac{\partial h_2(x)}{\partial x_2} & \frac{\partial h_2(x)}{\partial x_3} \end{bmatrix} = \begin{bmatrix} 2(x_1 + x_2) & -2x_2 & 2(x_1 + x_2) + 1 \\ 1 & 4(x_2^2 - x_3)x_2 & 1 - 2(x_2^2 - x_3) \end{bmatrix}$$





1.4 凸集和凸函数

1.4.1 凸集

定义1.4.1 设 S 为 n 维欧氏空间 \mathbb{R}^n 中一个集合。若对 S 中任意两点，联结它们的线段仍属于 S ；换言之，对 S 中任意两点 $x^{(1)}$ ， $x^{(2)}$ 及每个实数 $\lambda \in [0,1]$ ，都有

$$\lambda x^{(1)} + (1 - \lambda)x^{(2)} \in S,$$

则称 S 为凸集。



$$x^{(2)} + \lambda(x^{(1)} - x^{(2)})$$

1.4.1 凸集

例1.4.1 验证集合 $H = \{x | p^T x = \alpha\}$ 为凸集, 其中, p 为 n 维列向量, α 为实数。

解 由于对任意两点 $x^{(1)}, x^{(2)} \in H$, 有

$$p^T x^{(1)} = \alpha, \quad p^T x^{(2)} = \alpha$$

$\forall \lambda \in [0, 1]$, 有

$$p^T [\lambda x^{(1)} + (1 - \lambda)x^{(2)}] = \lambda p^T x^{(1)} + (1 - \lambda)p^T x^{(2)} = \alpha,$$

因此 $\lambda x^{(1)} + (1 - \lambda)x^{(2)} \in H$ 。

根据定义1.4.1知 H 为凸集。

集合 H 称为 \mathbb{R}^n 中的超平面, 故**超平面**为**凸集**。


例1.4.2 验证集合 $H^- = \{x | p^T x \leq \alpha\}$ 为凸集。

解 对任意的 $x^{(1)}, x^{(2)} \in H$ 及每一个实数 $\lambda \in [0, 1]$, 都有

$$p^T [\lambda x^{(1)} + (1 - \lambda)x^{(2)}] = \lambda p^T x^{(1)} + (1 - \lambda)p^T x^{(2)} \leq \alpha,$$

所以 $\lambda x^{(1)} + (1 - \lambda)x^{(2)} \in H$ 。根据定义1.4.1知 H 为凸集。

集合 $H = \{x | p^T x \leq \alpha\}$ 称为半空间, 故**半空间**为**凸集**。





1.4.1 凸集

例1.4.3 验证集合 $L = \{x | x = x^{(0)} + \lambda d, \lambda \geq 0\}$ 为凸集, 其中 d 是给定的非零向量, $x^{(0)}$ 是定点。

解 因为对 $\forall x^{(1)}, x^{(2)} \in L$ 及 $\lambda \in [0, 1]$, 必有 $x^{(1)} = x^{(0)} + \lambda_1 d$, $x^{(2)} = x^{(0)} + \lambda_2 d$, $\lambda_1, \lambda_2 \geq 0$, 以及

$$\begin{aligned}\lambda x^{(1)} + (1 - \lambda)x^{(2)} &= \lambda(x^{(0)} + \lambda_1 d) + (1 - \lambda)(x^{(0)} + \lambda_2 d) \\ &= x^{(0)} + [\lambda\lambda_1 + (1 - \lambda)\lambda_2]d\end{aligned}$$

由于 $[\lambda\lambda_1 + (1 - \lambda)\lambda_2] \geq 0$, 因此有 $\lambda x^{(1)} + (1 - \lambda)x^{(2)} \in L$, 根据定义1.4.1知 L 为凸集。

集合 $L = \{x | x = x^{(0)} + \lambda d, \lambda \geq 0\}$ 称为射线, $x^{(0)}$ 为射线的顶点, 故射线为凸集。


设 S_1 和 S_2 为 \mathbb{R}^n 中两个凸集, β 是实数, 则

(1) $\beta S_1 = \{\beta x | x \in S_1\}$ 为凸集;

(2) $S_1 \cap S_2$ 为凸集;

(3) $S_1 + S_2 = \{x^{(1)} + x^{(2)} | x^{(1)} \in S_1, x^{(2)} \in S_2\}$ 为凸集;

(4) $S_1 - S_2 = \{x^{(1)} - x^{(2)} | x^{(1)} \in S_1, x^{(2)} \in S_2\}$ 为凸集。




1.4.1 凸集

定义1.4.2 设有集合 $C \subset \mathbb{R}^n$, 若对 C 中每一点 x , 当 λ 取任何非负数时, 都有 $\lambda x \in C$, 称 C 为**锥**, 又若 C 为凸集, 则称 C 为**凸锥**。

例1.4.4 向量集 $\alpha^{(1)}, \alpha^{(2)}, \dots, \alpha^{(k)}$ 的所有非负线性组合构成的集合

$$\left\{ \sum_{i=1}^k \lambda_i \alpha^{(i)} \mid \lambda_i \geq 0, i = 1, \dots, k \right\}$$

为凸锥。



1.4.1 凸集

定义1.4.3 有限个半空间的交

$$\{x | Ax \leq b\}$$

称为**多面集**，其中 A 为 $m \times n$ 矩阵， b 为 m 维向量.

$$a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \leq b_1$$

$$a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n \leq b_2$$

\vdots

$$a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n \leq b_m$$

例1.4.5 集合

$$S = \{x | x_1 + 2x_2 \leq 4, x_1 - x_2 \leq 1, x_1 \geq 0, x_2 \geq 0\}$$

为多面集。





图 1.4.2




1.4.1 凸集

定义1.4.4 设 S 为非空凸集, $x \in S$, 若 x 不能表示成 S 中两个不同点的凸组合; 换言之, 若假设 $x = \lambda x^{(1)} + (1 - \lambda)x^{(2)}$ ($\lambda \in (0,1)$), $x^{(1)}, x^{(2)} \in S$, 必推得 $x = x^{(1)} = x^{(2)}$, 则称 x 是凸集 S 的极点。



(a)



(b)

定理: 若 S 是紧凸集, 则 S 中的任一点都可以表示成极点的凸组合。



1.4.1 凸集

定义1.4.5 设 S 为 \mathbb{R}^n 中的闭凸集， d 为非零向量，如果对 S 中的每一个 x ，都有射线 $\{x + \lambda d | \lambda \geq 0\} \subset S$ ，

则称向量 d 为 S 的**方向**。又设 $d^{(1)}$ 和 $d^{(2)}$ 是 S 的两个方向，若对任何正数 λ ，有 $d^{(1)} \neq \lambda d^{(2)}$ ，则称 $d^{(1)}$ 和 $d^{(2)}$ 是两个不同的方向。若 S 的方向 d 不能表示成该集合的两个不同方向的正的线性组合，则称 d 为 S 的**极方向**。

显然，**有界集**不存在方向，因而不存在极方向，对于**无界集**才有方向的概念。

例1.4.6 对于集合 $S = \{(x_1, x_2) | x_2 \geq |x_1|\}$ ，凡是与向量 $(0, 1)^T$ 夹角小于或等于 45° 的向量，都是它的方向。其中 $(1, 1)^T$ 和 $(-1, 1)^T$ 是 S 的两个极方向。 S 的其他方向都能表示成这两个极方向的正线性组合。





图 1.4.4



1.4.1 凸集

例1.4.7 设 $S = \{x \mid Ax = b, x \geq 0\}$ 为非空集合, d 是非零向量。证明 d 为 S 的方向的充要条件是 $d \geq 0$ 且 $Ad = 0$ 。

证明 按照定义, d 为 S 的方向的充要条件是: 对每一个 $x \in S$, 有


$$\{x + \lambda d \mid \lambda \geq 0\} \subset S. \quad (1.4.1)$$

根据集合 S 的定义, (1.4.1) 式即

$$A(x + \lambda d) = b, \quad (1.4.2).$$

$$x + \lambda d \geq 0. \quad (1.4.3)$$

由于 $Ax = b$, $x \geq 0$ 及 λ 可取任意非负数, 因此由 (1.4.2) 式和 (1.4.3) 式知 $Ad = 0$ 及 $d \geq 0$ 。





1.4.1 凸集

定理1.4.1 (表示定理) 设 $S = \{x | Ax = b, x \geq 0\}$ 为**非空多面集**，则有：



- (1) 极点集非空，且存在有限个极点 $x^{(1)}, x^{(2)}, \dots, x^{(k)}$.
- (2) 极方向集合为空集的充要条件是 S 有界。若 S 无界，则存在有限个极方向 $d^{(1)}, d^{(2)}, \dots, d^{(l)}$ 。
- (3) $x \in S$ 的充要条件是：

$$x = \sum_{j=1}^k \lambda_j x^{(j)} + \sum_{j=1}^l \mu_j d^{(j)}$$

$$\sum_{j=1}^k \lambda_j = 1$$

$$\lambda_j \geq 0, \quad j = 1, \dots, k$$

$$\mu_j \geq 0, \quad j = 1, \dots, l$$





1.4.2 凸集分离定理





定义1.4.6 设 S_1 和 S_2 是 \mathbb{R}^n 中两个非空集合, $H = \{x | p^T x = a\}$ 为超平面。如果对每个 $x \in S_1$, 都有 $p^T x \geq a$, 对于每个 $x \in S_2$, 都有 $p^T x \leq a$ (或情形恰好相反), 则称超平面 H **分离**集合 S_1 和 S_2 。

定理1.4.2 设 S 为 \mathbb{R}^n 中的**闭凸集**, $y \notin S$, 则存在**惟一**的点 $\bar{x} \in S$, 使得

$$\|y - \bar{x}\| = \inf_{x \in S} \|y - x\|$$

$$\inf_{x \in S} x \quad x \in (0,1)$$


$$\min_{x \in S} x \quad x \in (0,1)$$





1.4.2 凸集分离定理

定理1.4.3 设 S 是 \mathbb{R}^n 中的非空闭凸集, $y \notin S$, 则存在非零向量 p 及数 $\varepsilon > 0$, 使得对每个点 $x \in S$, 成立 $p^T y \geq \varepsilon + p^T x$ 。



证明: 由于 S 是闭凸集, $y \notin S$, 则由定理 1.4.2 知, 存在 $\bar{x} \in S$, 使

$$\|y - \bar{x}\| = \inf_{x \in S} \|y - x\|$$

$$\text{令 } p = y - \bar{x}, \varepsilon = p^T(y - \bar{x})$$

$$\begin{aligned} \text{由于 } p^T(y - x) &= p^T(y - \bar{x} + \bar{x} - x) \\ &= p^T(y - \bar{x}) + p^T(\bar{x} - x) \\ &= \varepsilon + (y - \bar{x})^T(\bar{x} - x) \end{aligned}$$

$$\begin{aligned} \|y - \bar{x}\|^2 &\leq \|y - [\lambda x + (1 - \lambda)\bar{x}]\|^2 \\ &= \|(y - \bar{x}) + \lambda(x - \bar{x})\|^2 \\ &= \|y - \bar{x}\|^2 + \lambda^2\|x - \bar{x}\|^2 + 2\lambda(y - \bar{x})^T(\bar{x} - x) \end{aligned}$$

$$\text{所以 } (y - \bar{x})^T(\bar{x} - x) + \frac{\lambda}{2}\|x - \bar{x}\|^2 \geq 0$$

$$\text{令 } \lambda \rightarrow 0, \text{ 则 } (y - \bar{x})^T(\bar{x} - x) \geq 0$$



$$\text{所以 } p^T(y - x) \geq \varepsilon$$

$$\text{即 } p^T y \geq \varepsilon + p^T x$$



1.4.2 凸集分离定理

定理1.4.4 设 S 是 \mathbb{R}^n 中一个非空凸集, $y \in \partial S$, 则存在非零向量 p , 使得对每一点 $x \in clS$, 有 $p^T y \geq p^T x$ 成立。



推论 设 S 是 \mathbb{R}^n 中的非空凸集, $y \notin S$, 则存在非零向量 p , 使得对每一点 $x \in clS$, 有 $p^T(x - y) \leq 0$ 。



1.4.2 凸集分离定理

定理1.4.5 设 S_1 和 S_2 是 \mathbb{R}^n 中两个非空凸集, $S_1 \cap S_2 = \emptyset$, 则存在非零向量 \mathbf{p} , 使

$$\inf\{\mathbf{p}^T \mathbf{x} | \mathbf{x} \in S_1\} \geq \sup\{\mathbf{p}^T \mathbf{x} | \mathbf{x} \in S_2\}$$

证明 令

$$S = S_1 - S_2 = \{\mathbf{z} | \mathbf{z} = \mathbf{x}^{(2)} - \mathbf{x}^{(1)}, \mathbf{x}^{(1)} \in S_1, \mathbf{x}^{(2)} \in S_2\}$$

由于 S_1 和 S_2 为非空凸集, 因此 S 是非空凸集。

根据定理1.4.4的推论, 存在非零向量 \mathbf{p} , 使得对于每一个 $\mathbf{z} \in S$, 成立 $\mathbf{p}^T \mathbf{z} \leq 0$ 。

$$\mathbf{p}^T (\mathbf{x}^{(2)} - \mathbf{x}^{(1)}) \leq 0$$

$$\mathbf{p}^T \mathbf{x}^{(1)} \geq \mathbf{p}^T \mathbf{x}^{(2)}$$



1.4.2 凸集分离定理

(1) Farkas定理

设 A 为 $m \times n$ 矩阵, c 为 n 维向量, 则 $Ax \leq 0, c^T x > 0$ 有解的充要条件是 $A^T y = c, y \geq 0$ 无解。

证明 先证必要性

设 $Ax \leq 0, c^T x > 0$ 有解, 即存在 \bar{x} , 使 $A\bar{x} \leq 0, c^T \bar{x} > 0$ 。现在证明 $A^T y = c, y \geq 0$ 无解。

用反证法, 设存在 $y \geq 0$, 使

$$A^T y = c$$

两端转置, 并右乘 \bar{x} , 得到

$$y^T A\bar{x} = c^T \bar{x}$$

由于 $y \geq 0, A\bar{x} \leq 0$, 因此 $y^T A\bar{x} \leq 0$, 因此 $y^T A\bar{x} \leq 0$ 得到 $c^T \bar{x} \leq 0$, 与 $c^T \bar{x} > 0$ 的假设矛盾。



1.4.2 凸集分离定理

(1) Farkas定理

设 A 为 $m \times n$ 矩阵, c 为 n 维向量, 则 $Ax \leq 0, c^T x > 0$ 有解的充要条件是 $A^T y = c, y \geq 0$ 无解。

再证明充分性 $A^T y = c, y \geq 0$ 无解, 证明 $Ax \leq 0, c^T x > 0$ 有解, 令

$$S = \{z = A^T y = c, y \geq 0\}$$

则 S 为闭凸集。由假设 $c \notin S$, 根据定理1.4.3, 存在非零向量 x 及数 $\varepsilon > 0$, 使得对每一个点 $z \in S$, 有

$$x^T c \geq \varepsilon + x^T z$$

由于 $\varepsilon > 0$, 必有 $x^T c > x^T z$

两端转置, 并考虑到集合 S 的定义, 有 $c^T x > z^T x = y^T Ax$

令 $y = 0$, 得 $c^T x > 0$

由于 $c^T x$ 为某个确定的数, $y \geq 0$, y 的分量可取任意大, 因此得出 $Ax \leq 0$

综上, 非零向量 x 是 $Ax \leq 0, c^T x > 0$ 的解。



1.4.2 凸集分离定理

(2) Gordan 定理

设 A 为 $m \times n$ 矩阵, 那么, $Ax < 0$ 有解的充要条件是不存在非零向量 $y \geq 0$, 使 $A^T y = 0$ 。

A^T 是 \mathbb{R}^n 中一组基, 由 m 个 n 维列向量组成, 只存在两种情况:

- (1) 存在一个方向, 与 A 中所有向量都呈钝角。
- (2) A^T 这组基的非负、非零线性组合可以得到原点。

1.4.3 凸函数

定义1.4.7 设 S 为 \mathbb{R}^n 中的非空凸集, f 是定义在 S 上的实函数, 如果对任意的 $x^{(1)}, x^{(2)} \in S$ 及每个数 $\lambda \in (0,1)$, 都有

$$f(\lambda x^{(1)} + (1 - \lambda)x^{(2)}) \leq \lambda f(x^{(1)}) + (1 - \lambda)f(x^{(2)})$$



则称 f 为 S 上的**凸函数**。

如果对任意互不相同的 $x^{(1)}, x^{(2)} \in S$, 及每一个数 $\lambda \in (0,1)$, 都有

$$f(\lambda x^{(1)} + (1 - \lambda)x^{(2)}) < \lambda f(x^{(1)}) + (1 - \lambda)f(x^{(2)})$$

则称 f 为 S 上的**严格凸函数**。

如果 $-f$ 为 S 上的凸函数, 则称 f 为 S 上的凹函数。






1.4.3 凸函数

例1.4.8 一元函数 $f(x) = |x|$ 是 \mathbb{R}^1 上的凸函数.

解 对任意的 $x^{(1)}, x^{(2)} \in \mathbb{R}^1$ 及每个数 $\lambda \in (0,1)$, 均有

$$\begin{aligned} f(\lambda x^{(1)} + (1 - \lambda)x^{(2)}) &= |\lambda x^{(1)} + (1 - \lambda)x^{(2)}| \\ &\leq \lambda |x^{(1)}| + (1 - \lambda)|x^{(2)}| \\ &= \lambda f(x^{(1)}) + (1 - \lambda)f(x^{(2)}) \end{aligned}$$

因此, 由定义1.4.7知, $f(x) = |x|$ 为凸函数。



1.4.3 凸函数

2. 凸函数的性质


定理1.4.8 设 f 是定义在凸集 S 上的凸函数, 实数 $\lambda \geq 0$, 则 λf 也是定义在 S 上的凸函数。

定理1.4.9 设 f_1 和 f_2 是定义在凸集 S 上的凸函数, 则 $f_1 + f_2$ 也是定义在 S 上的凸函数。

推论 设 f_1, f_2, \dots, f_k 定义在凸集 S 上的凸函数, 实数 $\lambda_1, \lambda_2, \dots, \lambda_k \geq 0$, 则 $\sum_{i=1}^k \lambda_i f_i$ 也是定义在 S 上的凸函数。

定理1.4.10 设 S 是 \mathbb{R}^n 中一个非空凸集, f 是定义在 S 上的凸函数, α 是一个实数, 则
水平集 $S_\alpha = \{x | x \in S, f(x) \leq \alpha\}$ 是凸集。

定理1.4.11 设 S 是 \mathbb{R}^n 中一个凸集, f 是定义在 S 上的凸函数, 则 f 在 S 的内部连续。



1.4.3 凸函数

定义1.4.8 设 S 是 \mathbb{R}^n 中一个集合, f 是定义在 S 上的实函数, $\bar{x} \in \text{int } S$, \boldsymbol{d} 是非零向量, f 在 \bar{x} 处沿方向 \boldsymbol{d} 的**方向导数** $Df(\bar{x}; \boldsymbol{d})$ 定义为下列极限:

$$Df(\bar{x}; \boldsymbol{d}) = \lim_{\lambda \rightarrow 0} \frac{f(\bar{x} + \lambda \boldsymbol{d}) - f(\bar{x})}{\lambda}, \quad (1.4.25)$$

这里假设上述极限存在。 $\text{int } S$ 表示集合 S 的内部。
 f 在 \bar{x} 处沿方向 \boldsymbol{d} 的右侧导数定义为

$$D^+ f(\bar{x}; \boldsymbol{d}) = \lim_{\lambda \rightarrow 0^+} \frac{f(\bar{x} + \lambda \boldsymbol{d}) - f(\bar{x})}{\lambda}$$

假设, 上述极限存在 f 在 \bar{x} 处沿方向 \boldsymbol{d} 的左侧导数定义为

$$D^- f(\bar{x}; \boldsymbol{d}) = \lim_{\lambda \rightarrow 0^-} \frac{f(\bar{x} + \lambda \boldsymbol{d}) - f(\bar{x})}{\lambda}$$

在(1.4.25)式中, 若方向 $\boldsymbol{d} = (0, \dots, 0, 1, 0, \dots, 0)^T$, 其中第 j 个分量是1, 其余 $n - 1$ 个分量全是零, 则 f 在 \bar{x} 处沿方向 \boldsymbol{d} 的方向导数正好等于 f 对 x_j 的偏导数, 即

$$Df(\bar{x}; \boldsymbol{d}) = \frac{\partial f(\bar{x})}{\partial x_j}$$

$$Df(\bar{x}; \boldsymbol{d}) = \boldsymbol{d}^T \nabla f(\bar{x})$$



1.4.3 凸函数

定理1.4.13 设 S 是 \mathbb{R}^n 中非空凸集, f 是定义在 S 上的凸函数, 则 f 在 S 上的局部极小点是全局极小点, 且极小点的集合为凸集。

证明 设 \bar{x} 是 f 在 S 上的局部极小点, 即存在 \bar{x} 的 $\varepsilon > 0$ 邻域 $N_\varepsilon(\bar{x})$, 使得对每一点 $x \in S \cap N_\varepsilon(\bar{x})$, 成立 $f(x) \geq f(\bar{x})$.

假设 \bar{x} 不是全局极小点, 则存在 $\hat{x} \in S$, 使 $f(\hat{x}) < f(\bar{x})$ 。由于 S 是凸集, 因此对每一个数 $\lambda \in [0,1]$, 有 $\lambda\hat{x} + (1-\lambda)\bar{x} \in S$ 。由于 \hat{x} 与 \bar{x} 是不同的两点, 可取 $\lambda \in (0,1)$ 。又由于 f 是 S 上的凸函数, 因此有

$$\begin{aligned} f(\lambda\hat{x} + (1-\lambda)\bar{x}) &\leq \lambda f(\hat{x}) + (1-\lambda)f(\bar{x}) \\ &< \lambda f(\bar{x}) + (1-\lambda)f(\bar{x}) \\ &< f(\bar{x}) \end{aligned}$$

当 λ 取得充分小时,可使

$$\lambda\hat{x} + (1-\lambda)\bar{x} \in S \cap N_\varepsilon(\bar{x}),$$

这与 \bar{x} 为局部极小点矛盾。故 \bar{x} 是 f 在 S 上的全局极小点。



1.4.4 凸函数的判别

定理1.4.14 设 S 是 \mathbb{R}^n 中非空开凸集, $f(x)$ 是定义在 S 上的可微函数, 则 $f(x)$ 为凸函数的充要条件是对任意两点 $x^{(1)}, x^{(2)} \in S$, 都有

$$f(x^{(2)}) \geq f(x^{(1)}) + \nabla f(x^{(1)})(x^{(2)} - x^{(1)})$$

而 $f(x)$ 为严格凸函数的充要条件是对任意的互不相同的 $x^{(1)}, x^{(2)} \in S$, 成立

$$f(x^{(2)}) > f(x^{(1)}) + \nabla f(x^{(1)})(x^{(2)} - x^{(1)})$$

推论 设 S 是 \mathbb{R}^n 中的凸集, $\bar{x} \in S$, $f(x)$ 是定义在 \mathbb{R}^n 上的凸函数, 且在点 x 可微, 则对任意的 $x \in S$, 有

$$f(x) \geq f(\bar{x}) + \nabla f(\bar{x})(x - \bar{x})$$




图 1.4.6



1.4.4 凸函数的判别

定理1.4.15 设 S 是 \mathbb{R}^n 中非空开凸集, $f(x)$ 是定义在 S 上的二次可微函数, 则 $f(x)$ 为凸函数的充要条件是在每一点 $x \in S$ 处Hesse矩阵半正定。

定理1.4.16 设 S 是 \mathbb{R}^n 中非空开凸集, $f(x)$ 是定义在 S 上的二次可微函数, 如果在每一点 $x \in S$, Hesse矩阵正定, 则 $f(x)$ 为严格凸函数。

注意: 逆定理并不成立。若 $f(x)$ 是定义在 S 上的严格凸函数, 则在每一点 $x \in S$ 处, Hesse矩阵是半正定的。



1.4.4 凸函数的判别

例1.4.9 二次函数

$$f(x_1, x_2) = 2x_1^2 + x_2^2 - 2x_1x_2 + x_1 + 1$$

是严格凸函数。

因为

$$\nabla f(\mathbf{x}) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{pmatrix} = \begin{pmatrix} 4x_1 - 2x_2 + 1 \\ 2x_2 - 2x_1 \end{pmatrix}$$

$$\nabla^2 f(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} \end{pmatrix} = \begin{pmatrix} 4 & -2 \\ -2 & 2 \end{pmatrix}$$

是正定的，因此 $f(\mathbf{x})$ 是严格凸函数。



1.4.5 凸规划

极小化问题

$$\min f(\mathbf{x})$$

$$s.t. g_i(\mathbf{x}) \geq 0, i = 1, \dots, m,$$


$$h_j(\mathbf{x}) = 0, j = 1, \dots, l,$$

设 $f(\mathbf{x})$ 是凸函数, $g_i(\mathbf{x})$ 是凹函数, $h_j(\mathbf{x})$ 是线性函数, 问题的可行域是

$$S = \{\mathbf{x} | g_i(\mathbf{x}) \geq 0, i = 1, \dots, m, h_j(\mathbf{x}) = 0, j = 1, \dots, l\}$$

凸规划: 求凸函数在凸集上的极小点。

凸规划的局部极小点就是全局极小点, 且极小点的集合是凸集。如果凸规划的目标函数是严格凸函数, 又存在极小点, 那么它的极小点是唯一的。



The end

